11501 金融上雲實務｜逢甲大學 金融創新場域課程｜期中提案書

MLOps in Finance：
風險模型從開發到雲端部署

國泰金控 數數發 出題主題：MLOps

第 13 組

PO 高慶霖｜SM 涂苙程｜資料工程 陳堃益｜模型開發 林冠宇｜雲端部署 賴政豪

GitHub：https://github.com/chinglin-k/fincloud-mlops-risk（Private）

繳交日期：2026 年 11 月 4 日

第 1 章　問題與動機

1.1 誰的什麼問題

銀行授信風控團隊已經會「開發」信用風險模型，困難在於「上線之後」：模型從資料科學家的筆電交到正式系統，往往要經過數週的人工打包、驗證與簽核；上線後也缺乏版本紀錄與漂移監控，等到逾放比上升才發現模型早已失準。模型失準會直接反映在信用損失上；沒有版本紀錄，也無法向主管機關說明某一筆案件是用哪一版模型、依據哪些變數評分。

1.2 對應企業爲何需要

國泰金控數數發在 10/29 業界出題中把 MLOps 列爲六大主題之一，強調模型的可追溯、可監控與快速部署。金管會 2024 年 6 月發布《金融業運用人工智慧（AI）指引》，要求金融機構對 AI 系統負起治理與問責、透明與可解釋、系統穩健等責任；要做到這些要求，必須從模型生命週期管理著手。美國聯準會 SR 11-7 也把模型開發、驗證與使用後監控列爲模型風險管理的三個環節。

1.3 Product Goal

> **讓授信風控團隊在一個工作天內，把通過驗證的信用風險模型從開發環境安全部署到雲端，並且每一次評分都可追溯、可解釋、可監控漂移。**

1.4 選題理由（選題矩陣）

候選題目	資料可取得	Learner Lab 可做	組員能力	業界價值	總分
MLOps 風險模型	5（可合成）	4（S3、Lambda、Athena）	4	5	**18**
AI 信用風險	4	4	4	4	16
GenAI 知識助手	3	2（Bedrock 受限）	3	4	12
數位申貸	3	3	3	4	13

本組選擇 MLOps，主要考量兩點：資料可以完全合成，不必接觸眞實個資；部署與監控所需的 S3、Lambda、Athena、DynamoDB，課程都已實作過。

第 2 章　使用者與決策

2.1 誰看結果、做什麼決策

使用者	看什麼	做什麼決策
授信人員	單筆違約機率、建議、前三大因子	核准、轉人工覆核、補件
風控主管	AUC／KS、模型登錄狀態	是否核准新版模型上線
模型負責人	PSI 漂移報告	是否啓動重新訓練
法遵／稽核	DynamoDB 稽核軌跡、CloudTrail	抽查單筆決策是否可追溯

2.2 As-Is → To-Be 使用者旅程

階段	As-Is（現況）	To-Be（本專案）
開發	筆電上訓練，資料版本不明	make all 從合成資料一鍵重現，資料分三層
驗證	人工寄 Excel 報表	CI 自動測試，AUC < 0.70 直接擋下
部署	數週人工打包	模型 JSON 上 S3，Lambda 載入，當天上線
使用	只有分數，無法說明	回傳 PD、建議與前三大因子；高風險轉人工
監控	逾放上升才發現	每月 PSI 檢查，> 0.25 告警重訓

2.3 User Story（節錄 8 則，完整見 Scrum 證據）

#	User Story	驗收條件	點	MoSCoW
US1	身爲資料工程師，我想要可重現的合成授信資料，以便不使用任何眞實個資也能開發模型。	固定亂數種子產生 10,000 筆；不含姓名、身分證字號；含缺值、錯誤值、重複列各一類	5	Must
US2	身爲法遵人員，我想要資料分爲 raw／processed／curated 三層，以便追溯每一次清理並在 curated 層去識別化。	raw 唯讀；curated 無 customer_id、性別、年齡層；測試 test_no_sensitive_in_curated 通過	5	Must
US3	身爲授信風控主管，我想要一個可解釋的違約機率模型，以便在核貸前看到風險排序。	測試集 AUC ≥ 0.70、KS ≥ 0.30；輸出前三大影響因子	8	Must
US4	身爲模型驗證人員，我想要每次訓練都寫入模型登錄，以便知道線上用的是哪一版。	registry.json 含版本、指標、雜湊值、狀態；AUC 未達門檻標示 rejected	5	Must
US5	身爲授信系統，我想要呼叫雲端評分 API，以便在一秒內取得違約機率與建議。	Lambda 回傳 pd、decision、model_version；每次呼叫寫入 DynamoDB 稽核表	8	Must
US6	身爲開發組員，我想要每次推送都自動測試與訓練，以便品質不靠人工檢查。	GitHub Actions 執行 pytest＋make all；AUC < 0.70 時工作流程失敗	5	Should
US7	身爲模型負責人，我想要每月比對新資料分布，以便在模型失準前收到重訓告警。（業師回饋 Issue，label：mentor）	計算 9 項特徵 PSI；> 0.25 標示 ALERT 並輸出 retrain=true	5	Should
US8	身爲授信人員，我想要高風險案件一律轉人工覆核，以便模型不單獨做出不利客戶的決定。	PD ≥ 0.10 轉人工；PD ≥ 0.35 標示高風險；測試 test_high_risk_goes_to_human 通過	3	Should

第 3 章　資料與方法

3.1 資料來源與授權

全部資料由 `data/generate_data.py` 以固定亂數種子（seed=42）合成，共 10,100 筆（含刻意注入的 100 筆重複列）；另以 seed=7、drift=1.0 產生 3,030 筆「2026 年第一季」資料模擬分布漂移。沒有任何眞實個資，客户編號爲隨機 UUID，授權上不受限制，任何人 clone 後都能得到相同資料。違約標籤由負債比、額度使用率、遲繳次數等變數經邏輯函數加雜訊產生，參數參考信用評分教科書中常見的變數方向。

3.2 欄位字典

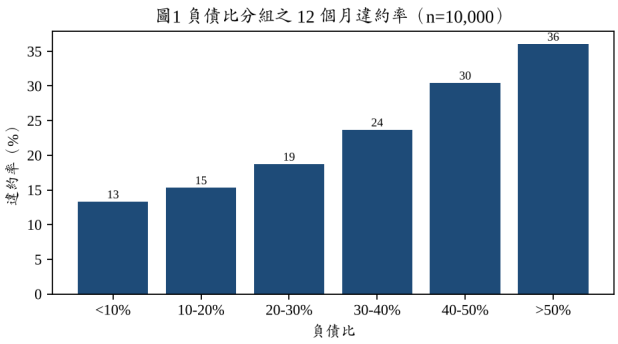
欄位	型態	說明	層別
customer_id → customer_token	string	raw 爲 UUID；curated 以 SHA-256＋鹽值 Token 化	raw／curated
annual_income	double	年收入（新臺幣元）	全部
employment_years	double	年資	全部
debt_ratio	double	負債比	全部
credit_utilization	double	循環額度使用率	全部
late_payments_12m	int	近 12 個月遲繳次數	全部
inquiries_6m	int	近 6 個月聯徵查詢次數	全部
num_credit_lines／loan_amount／loan_term_months	int／double／int	往來家數、申請金額、期數	全部
gender／age_band	string	敏感屬性，只用於公平性監控	另存，不入模
default_12m	int	12 個月內違約（目標）	全部

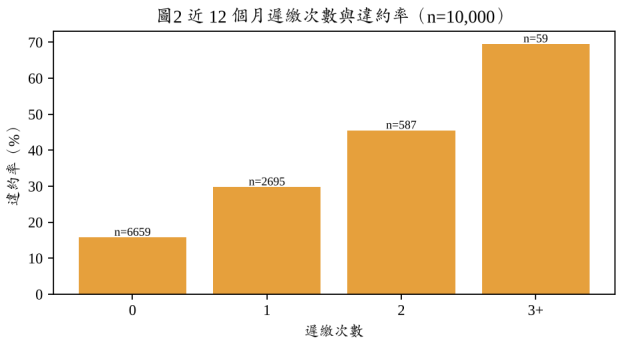
3.3 品質診斷與清理決策

問題	筆數	清理決策	理由
重複列	100	刪除	避免同一申請重複計算
年收入缺值	300	中位數補值＋缺值旗標	保留樣本，讓模型學到「缺值」本身的訊號
負債比 9.99 錯誤值	55	視爲缺值後補中位數＋旗標	9.99 是系統預設值，不是眞實負債

清理後 10,000 筆，整體違約率 21.6%。

3.4 三張圖與三則洞察

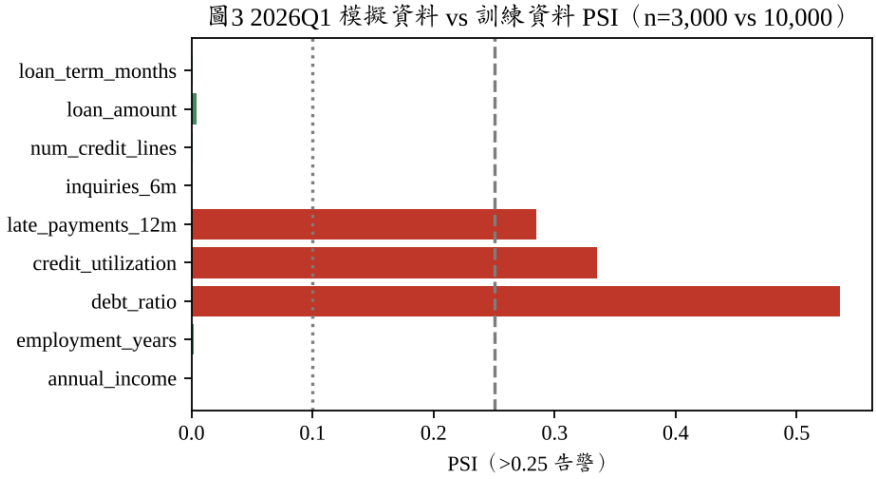




洞察 1（發現 → 假設 → 下一步）：負債比 20% 以下的違約率約 14.6%，超過 50% 升到 36.0%。假設負債比是最穩定的風險來源；下一步在 Sprint 3 以分箱（WoE）檢查單調性。

洞察 2：近 12 個月零遲繳的違約率 15.8%，三次以上高達 69.5%，但三次以上的樣本較少。假設遲繳次數是最強的單一指標；下一步檢查樣本數不足的分組是否需要合併，避免過度配適。

圖3 2026Q1 模擬資料 vs 訓練資料 PSI（n=3,000 vs 10,000）

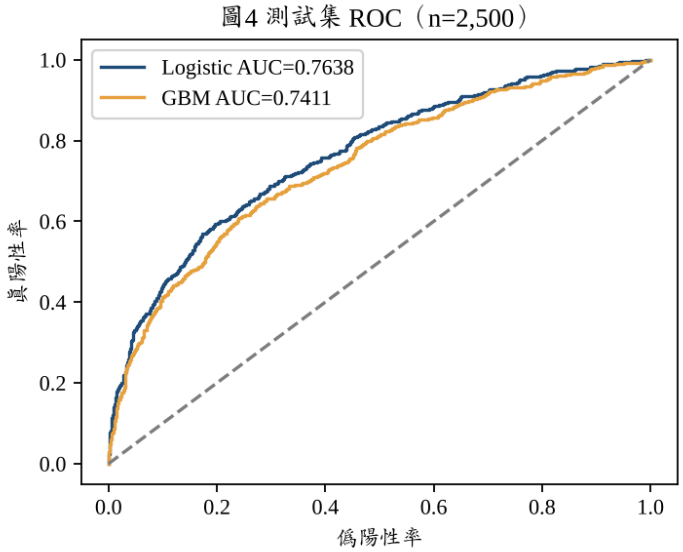


洞察 3：模擬的 2026 年第一季資料中，負債比、額度使用率、遲繳次數的 PSI 都超過 0.25，而這三項正是模型最重要的特徵。假設景氣轉弱時模型會最先失準；下一步把 PSI 告警接到重新訓練流程，並在 Sprint 3 比較重訓前後的 AUC。

3.5 分析方法

以 75／25 分層抽樣切分訓練與測試集。冠軍模型爲標準化後的 Logistic Regression（可解釋、係數可直接匯出成 JSON 給 Lambda 使用）；挑戰者爲 HistGradientBoosting。評估指標爲 AUC 與 KS。結果：Logistic AUC 0.7638、KS 0.397；GBM AUC 0.7411、KS 0.3686（測試集 n=2,500）。因爲 Logistic 表現較好且可解釋，維持爲冠軍模型（決策紀錄 D3）。

圖4 測試集 ROC（n=2,500）



第 4 章　方法與 AWS 架構

4.1 架構圖

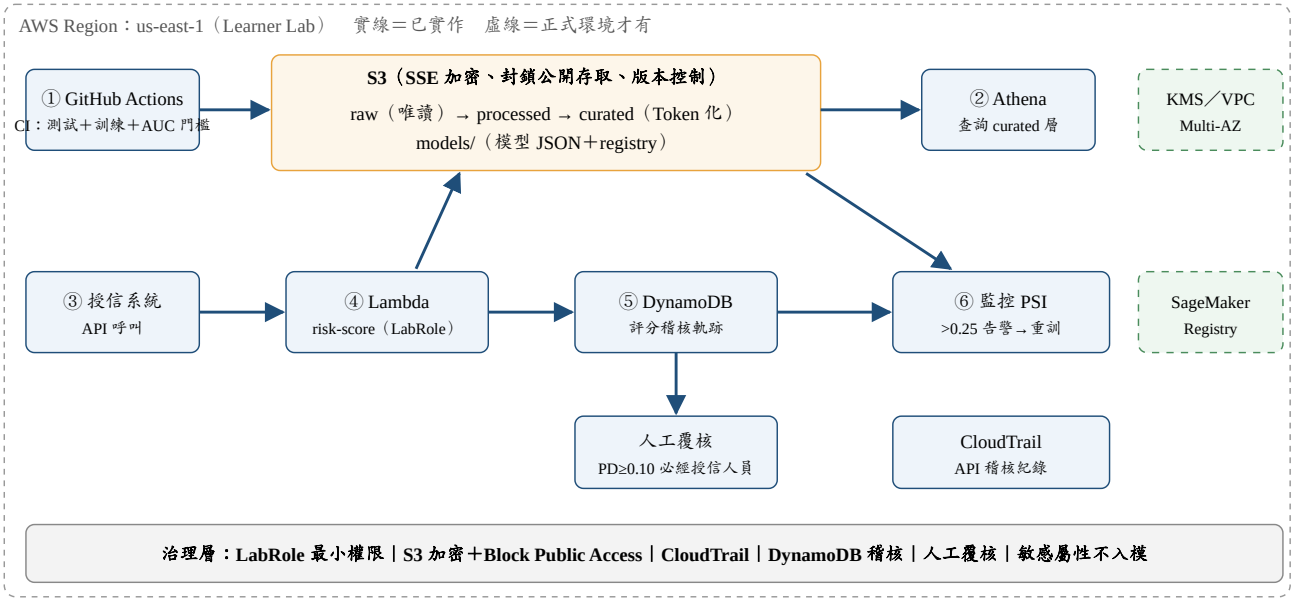


圖 5　端到端架構（①–⑥ 爲資料流順序；實線爲 Learner Lab 已實作，虛線爲正式環境元件）

4.2 觸發點與資料分層

① 開發者推送程式後，GitHub Actions 執行測試、訓練與 AUC 門檻檢查，通過後由部署腳本把資料與模型上傳 S3。資料分三層：raw 唯讀、保留原貌供稽核；processed 完成去重與補值；curated 再做 Token 化並移除敏感屬性。② Athena 直接查詢 curated 層。③ 授信系統以 API 呼叫 ④ Lambda，Lambda 從 S3 載入模型 JSON 進行評分，⑤ 結果逐筆寫入 DynamoDB 稽核表。⑥ 每月以 PSI 比對新資料與訓練資料，超過門檻即發出重新訓練告警。

4.3 服務選型理由與替代方案

需求	選用	理由	替代方案
資料湖	S3	便宜、可加密、可版本控制，Athena 可直接查	RDS（結構固定、成本高）
線上評分	Lambda	按次計費、免管伺服器；Logistic 推論只需純 Python	EC2（需常駐與修補）、SageMaker Endpoint（Lab 權限與額度受限）
稽核紀錄	DynamoDB	單筆寫入延遲低、隨用隨付，以 request_id 查詢	RDS（需管理連線池）
查詢分析	Athena	無伺服器 SQL，按掃描量計費	Redshift（規模過大）
CI／CD	GitHub Actions	與 Repo 整合、免費額度足夠	CodePipeline（Lab 權限受限）

4.4 Learner Lab 可做與不可做

可做（已實作或腳本已備）	不可做 → 替代方案
S3 加密與封鎖公開存取、Athena、Lambda（LabRole）、DynamoDB、CloudWatch Logs	自建 IAM 角色 → 使用 LabRole，正式環境拆分訓練／部署／稽核角色

	SageMaker Model Registry → registry.json 存 S3 KMS 客戶管理金鑰 → SSE-S3 VPC Endpoint／Multi-AZ → 正式環境設計，圖中以虛線表示

第 5 章　指標與預期產出

5.1 指標與定義

指標	定義	目標	目前
模型鑑別力	測試集 AUC（ROC 曲線下面積）	≥ 0.70	0.7638
部署前置時間	程式推送到新模型可被 Lambda 呼叫的時間	≤ 1 工作天	約 3 分鐘（11/4 於 Learner Lab CloudShell 實測，從安裝套件到 Lambda 回傳）
漂移偵測	PSI > 0.25 的特徵在當月被告警的比例	100%	模擬資料 3/3 告警

5.2 MVP 範圍

期中 MVP 爲端到端第一段：合成資料 → S3 三層 → Athena 可查 → Logistic 基準模型 AUC → Lambda 評分 → DynamoDB 稽核。對應課程範例「國泰 3／4：資料上 S3、Athena 可查＋Logistic 基準模型 AUC」，並多做了線上評分與漂移監控。截圖與完整重現步驟見附錄 B。

5.3 成功的樣子

期末展示時，評審可以 clone Repo，以一個指令重建資料與模型；在 Learner Lab 呼叫一次 API 取得違約機率與建議，並在 DynamoDB 查到該筆評分的模型版本與時間。放入漂移資料後，系統會發出告警並產生新版模型，舊版仍保留在模型登錄中。

第 6 章　法遵、風險與成本

6.1 資料落地與委外

教學環境位於 us-east-1，只放合成資料。正式環境須依金管會《金融機構作業委託他人處理內部作業制度及程序辦法》（112 年 8 月 4 日修正）評估：選擇可落地臺灣的雲端區域、跨境傳輸須事前申報、保留稽核權與資料取回及退場機制。

6.2 個資與去識別化

只用合成資料；即使未來接眞實資料，customer_id 在 curated 層以 SHA-256＋鹽值 Token 化（鹽值存環境變數，不進 Repo）。性別、年齡層與特徵檔分離，只供公平性監控。raw 層保存期限設爲 5 年後以 S3 生命週期規則刪除。

6.3 最小權限、稽核與人工覆核

教學使用 LabRole；正式環境拆爲資料工程（只寫 processed／curated）、模型訓練（只讀 curated、只寫 models/）、評分服務（只讀 models/、只寫稽核表）、稽核（唯讀）四個角色。CloudTrail 記錄所有 API 呼叫；每筆評分寫入 DynamoDB。人工覆核門檻：PD < 0.10 自動核准建議；0.10–0.35 轉授信人員；≥ 0.35 標示高風險並由主管覆核，模型永不自動拒絕。

6.4 金管會 AI 指引六大原則對照

原則	我們的設計
治理與問責	模型登錄記錄版本、指標、雜湊值與核准狀態，PO 爲上線核准人。
公平性與以人爲本	性別、年齡不入模；按群組監控核准率；高風險必經人工。
隱私與客户權益	合成資料、Token 化、敏感屬性分離存放。
系統穩健與安全	CI 自動測試與 AUC 門檻；S3 加密、封鎖公開存取；PSI 漂移告警。
透明與可解釋	Logistic 冠軍模型，每筆回傳前三大影響因子。
永續發展	無伺服器架構按次計費，不用時不耗資源；模型輕量，不需 GPU。

6.5 成本試算（AWS Pricing Calculator，us-east-1，不含免費方案）

服務	使用量假設（月）	每月（USD）
Lambda（x86，128 MB）	100 萬次評分請求，每次 200 毫秒	0.62
S3 標準儲存	100 GB；PUT 10 萬次、GET 100 萬次	3.20
DynamoDB 隨用隨付	5 GB；寫入 100 萬次、讀取 10 萬次	1.89
Athena	每天 20 次查詢，每次掃描 1 GB	2.97
合計	**12 個月 104.16；三年約 312.48**	**8.68**

估算連結：https://calculator.aws/#/estimate?id=1e824c1048f35dd28db3850e7d57fe6ced01304c

此估算以正式上線一年的業務量爲假設；Learner Lab 實測只用 1 萬筆資料與數次呼叫，費用接近零。未計入 CloudWatch、CloudTrail、KMS 客户管理金鑰、VPC Endpoint 與每月重訓運算，正式環境須另列。持續計費控管：Lab 結束前執行 End Lab；DynamoDB 用隨用隨付；Athena 結果 Bucket 設 7 天生命週期。

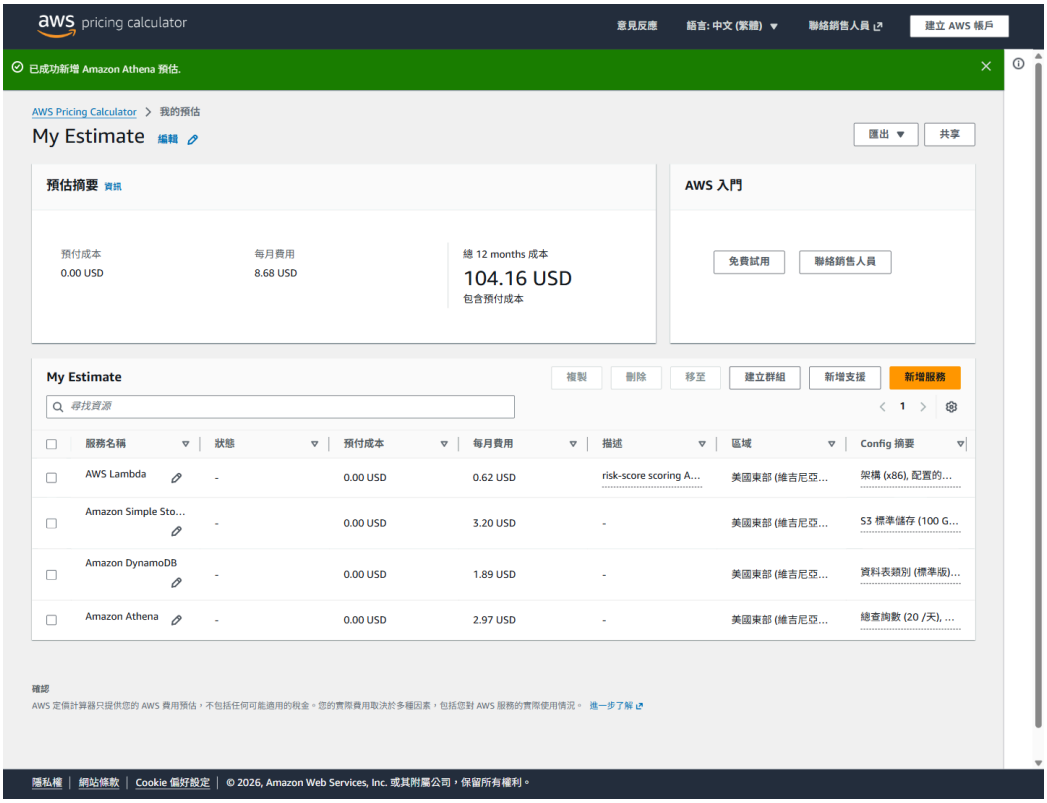


圖 6　AWS Pricing Calculator 估算摘要

6.6 風險登錄

風險	可能性	影響	對策	負責人
Learner Lab 額度用完	中	高	本機可完整重現；Lab 只跑部署段並及時 End Lab	賴政豪
Lab 不支援 SageMaker／自建 IAM	高	中	Lambda＋JSON 模型、registry.json 替代	賴政豪
合成資料與眞實分布落差	中	中	參數參考文獻；結論只談流程不談實際風險水準	陳堃益
模型漂移未被發現	中	高	PSI 月檢與告警，重訓走同一條 CI	林冠宇
金鑰外洩到 Repo	低	高	.gitignore、憑證只放本機、提交前掃描	涂苙程
模型對特定群組不公平	低	高	敏感屬性不入模、群組核准率監控	高慶霖

第 7 章　專案計畫（Scrum）

7.1 角色

PO 高慶霖、SM 涂苙程、Developers：陳堃益（資料）、林冠宇（模型）、賴政豪（雲端部署）。Sprint 爲兩週；每日站會 15 分鐘；看板欄位 Todo → In Progress → Done，網址：https://github.com/users/chinglin-k/projects/2 。

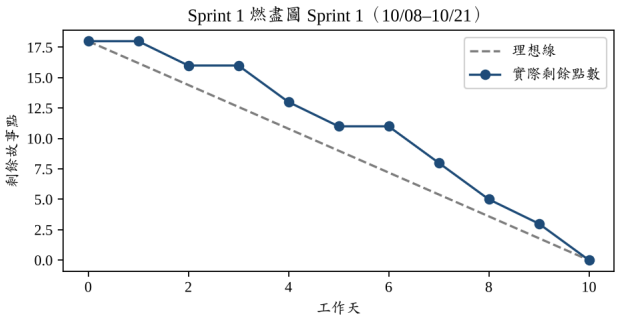
7.2 Definition of Done

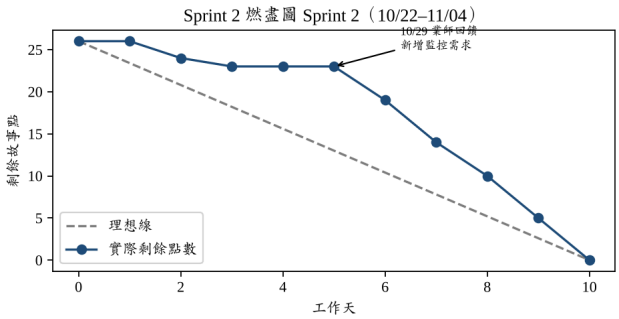
程式經 PR 審查並合併到 main；pytest 全數通過；CI 綠燈；README 或文件同步更新；不含金鑰與眞實個資。

7.3 Sprint 1–5 目標

Sprint	期間	目標	故事
1	10/08–10/21	合成資料、資料分層、基準模型	US1–US3（18 點，完成）
2	10/22–11/04	模型登錄、Lambda 評分、CI、漂移監控、人工覆核	US4–US8（26 點，完成）
3	11/12–11/25	依期中回饋修正；Learner Lab 全段驗證；公平性監控	US9、review Issue
4	11/26–12/09	漂移告警自動觸發重訓與冠軍／挑戰者切換；正式環境設計	US10
5	12/10–12/23	整合測試、成本驗證、期末報告與 Demo	收尾

7.4 Sprint 1–2 Increment 與 Retro





Sprint 1 Increment：可重現資料與 Logistic 基準模型。前四天燃盡圖幾乎不動，原因是任務切得太大；處理方式是 Sprint 2 每則故事拆 2–4 個 Task。Sprint 2 Increment：Lambda 評分、模型登錄、CI 門檻與 PSI 監控。第 4–6 天持平，原因是 10/29 業師回饋加入監控需求；處理方式是把 US7 從 Could 提升爲 Should 並拉進 Sprint 2，同時把原排的公平性儀表板（US9）延到 Sprint 3。

7.5 10/29 業師回饋如何調整 Backlog

業師指出，金融業導入 MLOps 最常遇到的問題出在模型上線後的監控與追溯。本組建立 Issue（label：mentor），並做三項調整：①新增 US7 漂移監控並提高優先序；②在 Lambda 加入 DynamoDB 稽核表（US5 驗收條件增加）；③新增決策紀錄 D5、D6。

附錄 A　Repo 結構與 AI 使用聲明

```
data/generate_data.py     合成資料產生腳本（seed、筆數、漂移強度可調）
src/clean.py              raw → processed → curated、Token 化
src/train.py              Logistic＋GBM、AUC／KS、模型登錄
src/score.py              純 Python 推論    src/lambda_function.py  Lambda＋稽核
src/monitor.py            PSI 漂移監控      src/make_figures.py     報告圖表
aws/deploy_learner_lab.sh、aws/athena/create_tables.sql、aws/sample_request.json
.github/workflows/ci.yml 測試＋訓練＋AUC 門檻
```

資料產生腳本說明：`python data/generate_data.py --n 10000 --seed 42` 產生訓練資料；`--drift 1.0` 讓負債比、額度使用率、遲繳次數往高風險方向偏移，模擬景氣轉弱。

AI 使用聲明：本組使用 Claude（Anthropic）協助產生程式骨架、合成資料腳本、文件初稿與圖表。所有內容由組員檢閱、執行與修改；文中數據均爲實際執行結果。

附錄 B　MVP 截圖與重現步驟

```
$ git clone <repo> && cd fincloud-mlops-risk && pip install -r requirements.txt
$ make all
python data/generate_data.py --n 10000 --seed 42 --out data/raw/applications.csv
wrote 10100 rows -> data/raw/applications.csv
python data/generate_data.py --n 3000 --seed 7 --drift 1.0 --out data/raw/applications_2026q1.csv
wrote 3030 rows -> data/raw/applications_2026q1.csv
python -m src.clean
{"rows": 10100, "duplicates": 100, "missing_income": 300, "invalid_debt_ratio": 55, "default_rate":
0.2158, "rows_after_clean": 10000}
python -m src.train
{"logistic": {"auc": 0.7638, "ks": 0.397}, "gbm": {"auc": 0.7411, "ks": 0.3686}, "n_train": 7500,
"n_test": 2500}
python -m src.monitor data/raw/applications.csv data/raw/applications_2026q1.csv
{"ALERT": ["debt_ratio", "credit_utilization", "late_payments_12m"], "retrain": true}
$ python -m pytest -q
.....                                                                    [100%]
5 passed in 0.32s
$ python src/local_demo.py   # 模擬 Lambda 評分
{"model_version": "v20261104150738", "pd": 0.7957, "decision": "MANUAL_REVIEW_HIGH_RISK", "top_factors":
["late_payments_12m", "credit_utilization", "debt_ratio"]}
{"model_version": "v20261104150738", "pd": 0.0131, "decision": "AUTO_APPROVE", "top_factors":
["late_payments_12m", "credit_utilization", "debt_ratio"]}
$ cat models/registry.json | tail -1 (節錄)
{"version": "v20261104150738", "champion": "logistic", "status": "staging", "sha256": "c79daa00a4ff"}
```

圖 B1　全新 clone 後執行 make all、pytest 與本機評分的實際輸出

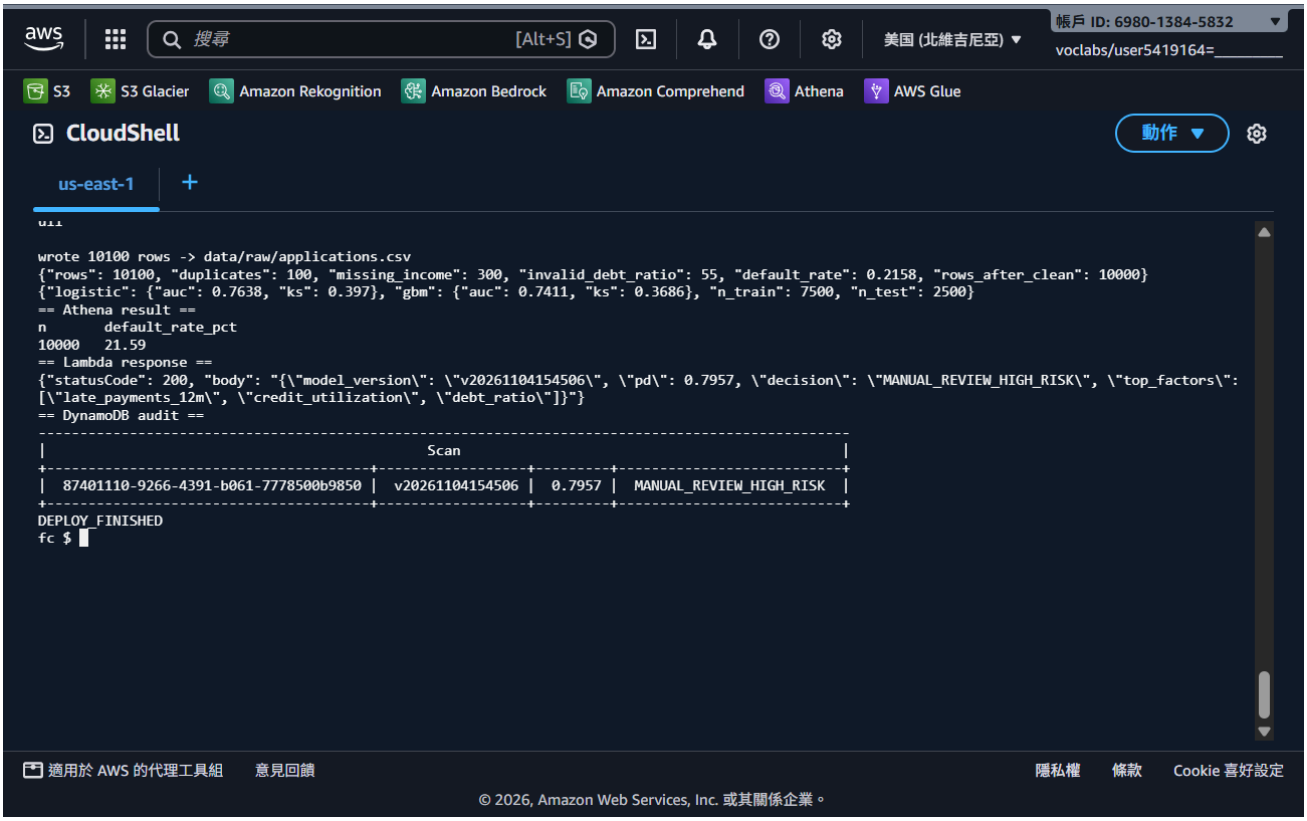


圖 B2　Learner Lab CloudShell 實際執行（2026/11/4，us-east-1）：Athena 查得 10,000 筆，Lambda 回傳 PD 0.7957 並寫入 DynamoDB 稽核表

重現步驟（Learner Lab）：1. Start Lab，開啓 AWS 主控臺的 CloudShell（已帶 LabRole 憑證）；2. clone Repo 後執行 `python3 -m pip install -r requirements.txt && make all`（CloudShell 不可加 --user）（10,100 筆 → 10,000 筆）；3. `bash aws/deploy_learner_lab.sh`：建立加密 S3、上傳三層資料與模型、Athena 建表查詢、建立 DynamoDB 與 Lambda 並呼叫一次；4. 在 Athena 主控臺執行 `SELECT COUNT(*) FROM fincloud_risk.features` 應爲 10,000；5. DynamoDB risk_score_audit 可看到評分紀錄；6. 結束後按 End Lab。

附錄 C　參考資料

Board of Governors of the Federal Reserve System. (2011). *SR 11-7: Guidance on model risk management*.

金融監督管理委員會. (2023). *金融機構作業委託他人處理內部作業制度及程序辦法*（112 年 8 月 4 日修正）.

金融監督管理委員會. (2024). *金融業運用人工智慧（AI）指引*（2024 年 6 月 20 日）.

Siddiqi, N. (2017). *Intelligent credit scoring* (2nd ed.). Wiley.

Amazon Web Services. (2025). *AWS Well-Architected Framework: Machine learning lens*.