11501 金融上雲實務｜逢甲大學 金融創新場域課程｜期中提案書

MLOps in Finance：
風險模型從開發到雲端部署

國泰金控 數數發 出題主題：MLOps

第 13 組

PO 高慶霖｜SM 涂苙程｜資料工程 陳堃益｜模型開發 林冠宇｜雲端部署 賴政豪

GitHub：https://github.com/chinglin-k/fincloud-mlops-risk（Private）

繳交日期：2026 年 11 月 4 日

第 1 章　問題與動機

1.1 誰的什麼問題

銀行授信風控團隊已經會「開發」信用風險模型，困難在於「上線之後」：模型從資料科學家的筆電交到正式系統，往往要經過數週的人工打包、驗證與簽核；上線後也缺乏版本紀錄與漂移監控，等到逾放比上升才發現模型早已失準。模型失準會直接反映在信用損失上；沒有版本紀錄，也無法向主管機關說明某一筆案件是用哪一版模型、依據哪些變數評分。

1.2 對應企業爲何需要

國泰金控數數發在 10/29 業界出題中把 MLOps 列爲六大主題之一，強調模型的可追溯、可監控與快速部署。金管會 2024 年 6 月發布《金融業運用人工智慧（AI）指引》，要求金融機構對 AI 系統負起治理與問責、透明與可解釋、系統穩健等責任；要做到這些要求，必須從模型生命週期管理著手。美國聯準會 SR 11-7 也把模型開發、驗證與使用後監控列爲模型風險管理的三個環節。

1.3 Product Goal

> **讓授信風控團隊在一個工作天內，把通過驗證的信用風險模型從開發環境安全部署到雲端，並且每一次評分都可追溯、可解釋、可監控漂移。**

1.4 選題理由（選題矩陣）

候選題目	資料可取得	Learner Lab 可做	組員能力	業界價值	總分
MLOps 風險模型	5（可合成）	4（S3、Lambda、Athena）	4	5	**18**
AI 信用風險	4	4	4	4	16
GenAI 知識助手	3	2（Bedrock 受限）	3	4	12
數位申貸	3	3	3	4	13

本組選擇 MLOps，主要考量兩點：資料可以完全合成，不必接觸眞實個資；部署與監控所需的 S3、Lambda、Athena、DynamoDB，課程都已實作過。

第 2 章　使用者與決策

2.1 誰看結果、做什麼決策

使用者	看什麼	做什麼決策
授信人員	單筆違約機率、建議、前三大因子	核准、轉人工覆核、補件
風控主管	AUC／KS、模型登錄狀態	是否核准新版模型上線
模型負責人	PSI 漂移報告	是否啓動重新訓練
法遵／稽核	DynamoDB 稽核軌跡、CloudTrail	抽查單筆決策是否可追溯

2.2 As-Is → To-Be 使用者旅程

階段	As-Is（現況）	To-Be（本專案）
開發	筆電上訓練，資料版本不明	make all 從合成資料一鍵重現，資料分三層
驗證	人工寄 Excel 報表	CI 自動測試，AUC < 0.70 直接擋下
部署	數週人工打包	模型 JSON 上 S3，Lambda 載入，當天上線
使用	只有分數，無法說明	回傳 PD、建議與前三大因子；高風險轉人工
監控	逾放上升才發現	每月 PSI 檢查，> 0.25 告警重訓

2.3 User Story（節錄 8 則，完整見 Scrum 證據）

#	User Story	驗收條件	點	MoSCoW
US1	身爲資料工程師，我想要可重現的合成授信資料，以便不使用任何眞實個資也能開發模型。	固定亂數種子產生 10,000 筆；不含姓名、身分證字號；含缺值、錯誤值、重複列各一類	5	Must
US2	身爲法遵人員，我想要資料分爲 raw／processed／curated 三層，以便追溯每一次清理並在 curated 層去識別化。	raw 唯讀；curated 無 customer_id、性別、年齡層；測試 test_no_sensitive_in_curated 通過	5	Must
US3	身爲授信風控主管，我想要一個可解釋的違約機率模型，以便在核貸前看到風險排序。	測試集 AUC ≥ 0.70、KS ≥ 0.30；輸出前三大影響因子	8	Must
US4	身爲模型驗證人員，我想要每次訓練都寫入模型登錄，以便知道線上用的是哪一版。	registry.json 含版本、指標、雜湊值、狀態；AUC 未達門檻標示 rejected	5	Must
US5	身爲授信系統，我想要呼叫雲端評分 API，以便在一秒內取得違約機率與建議。	Lambda 回傳 pd、decision、model_version；每次呼叫寫入 DynamoDB 稽核表	8	Must
US6	身爲開發組員，我想要每次推送都自動測試與訓練，以便品質不靠人工檢查。	GitHub Actions 執行 pytest＋make all；AUC < 0.70 時工作流程失敗	5	Should
US7	身爲模型負責人，我想要每月比對新資料分布，以便在模型失準前收到重訓告警。（業師回饋 Issue，label：mentor）	計算 9 項特徵 PSI；> 0.25 標示 ALERT 並輸出 retrain=true	5	Should
US8	身爲授信人員，我想要高風險案件一律轉人工覆核，以便模型不單獨做出不利客戶的決定。	PD ≥ 0.10 轉人工；PD ≥ 0.35 標示高風險；測試 test_high_risk_goes_to_human 通過	3	Should

第 3 章　資料與方法

3.1 資料來源與授權

全部資料由 `data/generate_data.py` 以固定亂數種子（seed=42）合成，共 10,100 筆（含刻意注入的 100 筆重複列）；另以 seed=7、drift=1.0 產生 3,030 筆「2026 年第一季」資料模擬分布漂移。沒有任何眞實個資，客户編號爲隨機 UUID，授權上不受限制，任何人 clone 後都能得到相同資料。違約標籤由負債比、額度使用率、遲繳次數等變數經邏輯函數加雜訊產生，參數參考信用評分教科書中常見的變數方向。

3.2 欄位字典

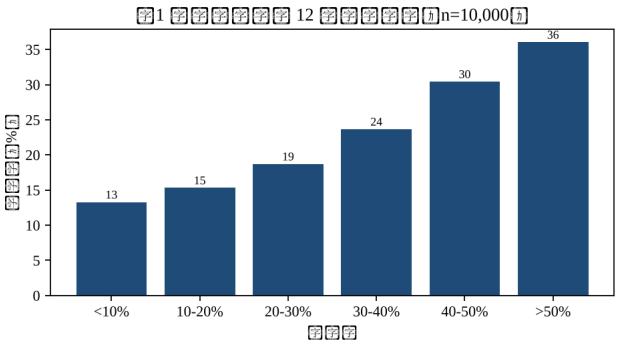
欄位	型態	說明	層別
customer_id → customer_token	string	raw 爲 UUID；curated 以 SHA-256＋鹽值 Token 化	raw／curated
annual_income	double	年收入（新臺幣元）	全部
employment_years	double	年資	全部
debt_ratio	double	負債比	全部
credit_utilization	double	循環額度使用率	全部
late_payments_12m	int	近 12 個月遲繳次數	全部
inquiries_6m	int	近 6 個月聯徵查詢次數	全部
num_credit_lines／loan_amount／loan_term_months	int／double／int	往來家數、申請金額、期數	全部
gender／age_band	string	敏感屬性，只用於公平性監控	另存，不入模
default_12m	int	12 個月內違約（目標）	全部

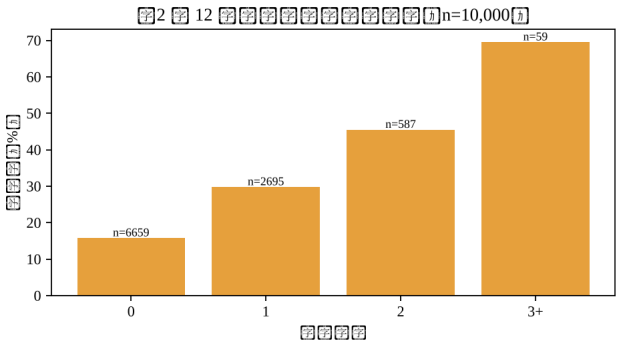
3.3 品質診斷與清理決策

問題	筆數	清理決策	理由
重複列	100	刪除	避免同一申請重複計算
年收入缺值	300	中位數補值＋缺值旗標	保留樣本，讓模型學到「缺值」本身的訊號
負債比 9.99 錯誤值	55	視爲缺值後補中位數＋旗標	9.99 是系統預設值，不是眞實負債

清理後 10,000 筆，整體違約率 21.6%。

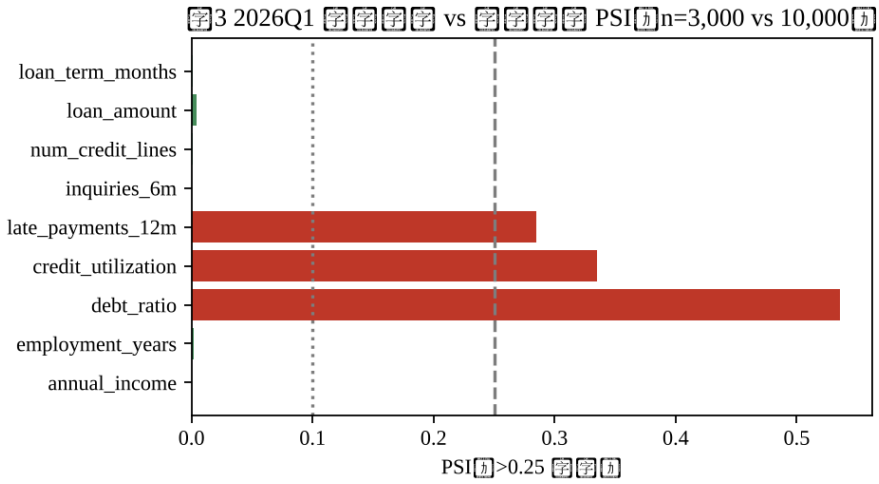
3.4 三張圖與三則洞察





洞察 1（發現 → 假設 → 下一步）：負債比 20% 以下的違約率約 14.6%，超過 50% 升到 36.0%。假設負債比是最穩定的風險來源；下一步在 Sprint 3 以分箱（WoE）檢查單調性。

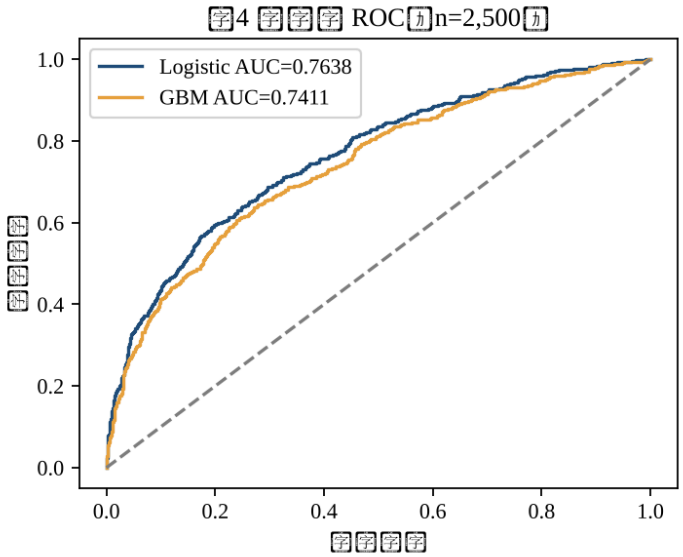
洞察 2：近 12 個月零遲繳的違約率 15.8%，三次以上高達 69.5%，但三次以上的樣本較少。假設遲繳次數是最強的單一指標；下一步檢查樣本數不足的分組是否需要合併，避免過度配適。



洞察 3：模擬的 2026 年第一季資料中，負債比、額度使用率、遲繳次數的 PSI 都超過 0.25，而這三項正是模型最重要的特徵。假設景氣轉弱時模型會最先失準；下一步把 PSI 告警接到重新訓練流程，並在 Sprint 3 比較重訓前後的 AUC。

3.5 分析方法

以 75／25 分層抽樣切分訓練與測試集。冠軍模型爲標準化後的 Logistic Regression（可解釋、係數可直接匯出成 JSON 給 Lambda 使用）；挑戰者爲 HistGradientBoosting。評估指標爲 AUC 與 KS。結果：Logistic AUC 0.7638、KS 0.397；GBM AUC 0.7411、KS 0.3686（測試集 n=2,500）。因爲 Logistic 表現較好且可解釋，維持爲冠軍模型（決策紀錄 D3）。



第 4 章　方法與 AWS 架構

4.1 架構圖

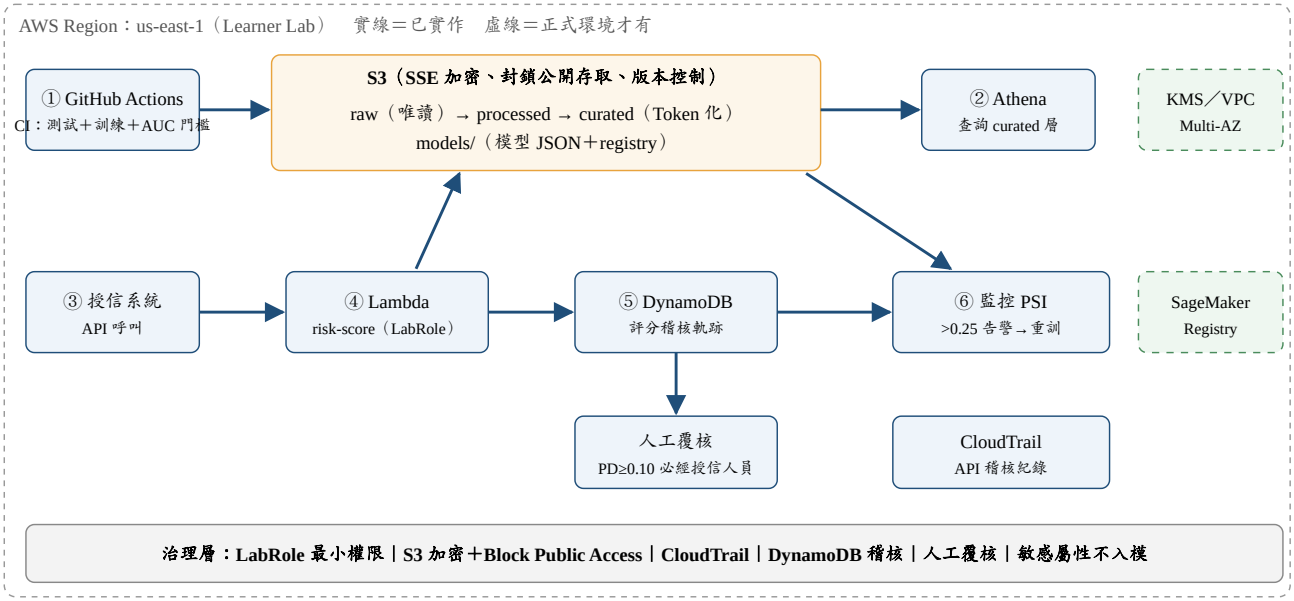


圖 5　端到端架構（①–⑥ 爲資料流順序；實線爲 Learner Lab 已實作，虛線爲正式環境元件）

4.2 觸發點與資料分層

① 開發者推送程式後，GitHub Actions 執行測試、訓練與 AUC 門檻檢查，通過後由部署腳本把資料與模型上傳 S3。資料分三層：raw 唯讀、保留原貌供稽核；processed 完成去重與補值；curated 再做 Token 化並移除敏感屬性。② Athena 直接查詢 curated 層。③ 授信系統以 API 呼叫 ④ Lambda，Lambda 從 S3 載入模型 JSON 進行評分，⑤ 結果逐筆寫入 DynamoDB 稽核表。⑥ 每月以 PSI 比對新資料與訓練資料，超過門檻即發出重新訓練告警。

4.3 服務選型理由與替代方案

需求	選用	理由	替代方案
資料湖	S3	便宜、可加密、可版本控制，Athena 可直接查	RDS（結構固定、成本高）
線上評分	Lambda	按次計費、免管伺服器；Logistic 推論只需純 Python	EC2（需常駐與修補）、SageMaker Endpoint（Lab 權限與額度受限）
稽核紀錄	DynamoDB	單筆寫入延遲低、隨用隨付，以 request_id 查詢	RDS（需管理連線池）
查詢分析	Athena	無伺服器 SQL，按掃描量計費	Redshift（規模過大）
CI／CD	GitHub Actions	與 Repo 整合、免費額度足夠	CodePipeline（Lab 權限受限）

4.4 Learner Lab 可做與不可做

可做（已實作或腳本已備）	不可做 → 替代方案
S3 加密與封鎖公開存取、Athena、Lambda（LabRole）、DynamoDB、CloudWatch Logs	自建 IAM 角色 → 使用 LabRole，正式環境拆分訓練／部署／稽核角色

	SageMaker Model Registry → registry.json 存 S3 KMS 客戶管理金鑰 → SSE-S3 VPC Endpoint／Multi-AZ → 正式環境設計，圖中以虛線表示

第 5 章　指標與預期產出

5.1 指標與定義

指標	定義	目標	目前
模型鑑別力	測試集 AUC（ROC 曲線下面積）	≥ 0.70	0.7638
部署前置時間	程式推送到新模型可被 Lambda 呼叫的時間	≤ 1 工作天	腳本約 5 分鐘（本機量測，待 Lab 驗證）
漂移偵測	PSI > 0.25 的特徵在當月被告警的比例	100%	模擬資料 3/3 告警

5.2 MVP 範圍

期中 MVP 爲端到端第一段：合成資料 → S3 三層 → Athena 可查 → Logistic 基準模型 AUC → Lambda 評分 → DynamoDB 稽核。對應課程範例「國泰 3／4：資料上 S3、Athena 可查＋Logistic 基準模型 AUC」，並多做了線上評分與漂移監控。截圖與完整重現步驟見附錄 B。

5.3 成功的樣子

期末展示時，評審可以 clone Repo，以一個指令重建資料與模型；在 Learner Lab 呼叫一次 API 取得違約機率與建議，並在 DynamoDB 查到該筆評分的模型版本與時間。放入漂移資料後，系統會發出告警並產生新版模型，舊版仍保留在模型登錄中。

第 6 章　法遵、風險與成本

6.1 資料落地與委外

教學環境位於 us-east-1，只放合成資料。正式環境須依金管會《金融機構作業委託他人處理內部作業制度及程序辦法》（112 年 8 月 4 日修正）評估：選擇可落地臺灣的雲端區域、跨境傳輸須事前申報、保留稽核權與資料取回及退場機制。

6.2 個資與去識別化

只用合成資料；即使未來接眞實資料，customer_id 在 curated 層以 SHA-256＋鹽值 Token 化（鹽值存環境變數，不進 Repo）。性別、年齡層與特徵檔分離，只供公平性監控。raw 層保存期限設爲 5 年後以 S3 生命週期規則刪除。

6.3 最小權限、稽核與人工覆核

教學使用 LabRole；正式環境拆爲資料工程（只寫 processed／curated）、模型訓練（只讀 curated、只寫 models/）、評分服務（只讀 models/、只寫稽核表）、稽核（唯讀）四個角色。CloudTrail 記錄所有 API 呼叫；每筆評分寫入 DynamoDB。人工覆核門檻：PD < 0.10 自動核准建議；0.10–0.35 轉授信人員；≥ 0.35 標示高風險並由主管覆核，模型永不自動拒絕。

6.4 金管會 AI 指引六大原則對照

原則	我們的設計
治理與問責	模型登錄記錄版本、指標、雜湊值與核准狀態，PO 爲上線核准人。
公平性與以人爲本	性別、年齡不入模；按群組監控核准率；高風險必經人工。
隱私與客戶權益	合成資料、Token 化、敏感屬性分離存放。
系統穩健與安全	CI 自動測試與 AUC 門檻；S3 加密、封鎖公開存取；PSI 漂移告警。
透明與可解釋	Logistic 冠軍模型，每筆回傳前三大影響因子。
永續發展	無伺服器架構按次計費，不用時不耗資源；模型輕量，不需 GPU。

6.5 成本試算（估算，待以 AWS Pricing Calculator 驗證並附連結）

項目	Learner Lab（月）	正式環境假設（月）
S3（1 GB／100 GB）	US$0.03	US$2.3
Athena（10 GB／1 TB 掃描）	US$0.05	US$5
Lambda（1 萬／100 萬次）	≈ US$0	US$0.4
DynamoDB 隨用隨付（1 萬／100 萬次寫入）	US$0.01	US$1.3
CloudWatch、CloudTrail、KMS	US$0.5	US$13
VPC Endpoint、每月重訓運算	—	US$48
合計	**≈ US$0.6／月**	**≈ US$70／月；三年 ≈ US$2,520**

持續計費控管：Lab 結束前執行 End Lab；DynamoDB 用隨用隨付；Athena 結果 Bucket 設 7 天生命週期。

6.6 風險登錄

風險	可能性	影響	對策	負責人
Learner Lab 額度用完	中	高	本機可完整重現；Lab 只跑部署段並及時 End Lab	賴政豪
Lab 不支援 SageMaker／自建 IAM	高	中	Lambda＋JSON 模型、registry.json 替代	賴政豪
合成資料與眞實分布落差	中	中	參數參考文獻；結論只談流程不談實際風險水準	陳堃益
模型漂移未被發現	中	高	PSI 月檢與告警，重訓走同一條 CI	林冠宇
金鑰外洩到 Repo	低	高	.gitignore、憑證只放本機、提交前掃描	涂苙程
模型對特定群組不公平	低	高	敏感屬性不入模、群組核准率監控	高慶霖

第 7 章　專案計畫（Scrum）

7.1 角色

PO 高慶霖、SM 涂芷程、Developers：陳堃益（資料）、林冠宇（模型）、賴政豪（雲端部署）。Sprint 爲兩週；每日站會 15 分鐘；看板欄位 Backlog → To Do → In Progress → Review → Done。

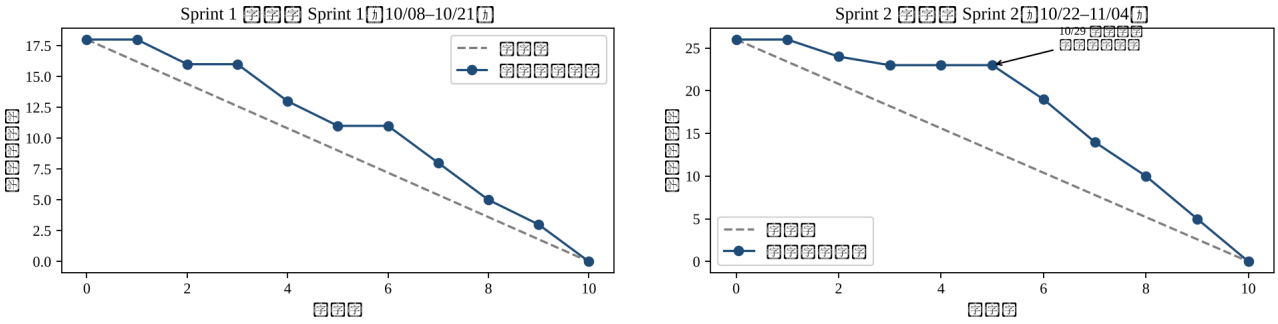
7.2 Definition of Done

程式經 PR 審查並合併到 main；pytest 全數通過；CI 綠燈；README 或文件同步更新；不含金鑰與眞實個資。

7.3 Sprint 1–5 目標

Sprint	期間	目標	故事
1	10/08–10/21	合成資料、資料分層、基準模型	US1–US3（18 點，完成）
2	10/22–11/04	模型登錄、Lambda 評分、CI、漂移監控、人工覆核	US4–US8（26 點，完成）
3	11/12–11/25	依期中回饋修正；Learner Lab 全段驗證；公平性監控	US9、review Issue
4	11/26–12/09	漂移告警自動觸發重訓與冠軍／挑戰者切換；正式環境設計	US10
5	12/10–12/23	整合測試、成本驗證、期末報告與 Demo	收尾

7.4 Sprint 1–2 Increment 與 Retro



Sprint 1 Increment：可重現資料與 Logistic 基準模型。前四天燃盡圖幾乎不動，原因是任務切得太大；處理方式是 Sprint 2 每則故事拆 2–4 個 Task。Sprint 2 Increment：Lambda 評分、模型登錄、CI 門檻與 PSI 監控。第 4–6 天持平，原因是 10/29 業師回饋加入監控需求；處理方式是把 US7 從 Could 提升爲 Should 並拉進 Sprint 2，同時把原排的公平性儀表板（US9）延到 Sprint 3。

7.5 10/29 業師回饋如何調整 Backlog

業師指出，金融業導入 MLOps 最常遇到的問題出在模型上線後的監控與追溯。本組建立 Issue（label：mentor），並做三項調整：①新增 US7 漂移監控並提高優先序；②在 Lambda 加入 DynamoDB 稽核表（US5 驗收條件增加）；③新增決策紀錄 D5、D6。

附錄 A　Repo 結構與 AI 使用聲明

```
data/generate_data.py     合成資料產生腳本（seed、筆數、漂移強度可調）
src/clean.py              raw → processed → curated、Token 化
src/train.py              Logistic＋GBM、AUC／KS、模型登錄
src/score.py              純 Python 推論    src/lambda_function.py  Lambda＋稽核
src/monitor.py            PSI 漂移監控      src/make_figures.py     報告圖表
aws/deploy_learner_lab.sh、aws/athena/create_tables.sql、aws/sample_request.json
.github/workflows/ci.yml 測試＋訓練＋AUC 門檻
```

資料產生腳本說明：`python data/generate_data.py --n 10000 --seed 42` 產生訓練資料；`--drift 1.0` 讓負債比、額度使用率、遲繳次數往高風險方向偏移，模擬景氣轉弱。

AI 使用聲明：本組使用 Claude（Anthropic）協助產生程式骨架、合成資料腳本、文件初稿與圖表。所有內容由組員檢閱、執行與修改；文中數據均爲實際執行結果。

附錄 B　MVP 截圖與重現步驟

```
$ git clone <repo> && cd fincloud-mlops-risk && pip install -r requirements.txt
$ make all
python data/generate_data.py --n 10000 --seed 42 --out data/raw/applications.csv
wrote 10100 rows -> data/raw/applications.csv
python data/generate_data.py --n 3000 --seed 7 --drift 1.0 --out data/raw/applications_2026q1.csv
wrote 3030 rows -> data/raw/applications_2026q1.csv
python -m src.clean
{"rows": 10100, "duplicates": 100, "missing_income": 300, "invalid_debt_ratio": 55, "default_rate":
0.2158, "rows_after_clean": 10000}
python -m src.train
{"logistic": {"auc": 0.7638, "ks": 0.397}, "gbm": {"auc": 0.7411, "ks": 0.3686}, "n_train": 7500,
"n_test": 2500}
python -m src.monitor data/raw/applications.csv data/raw/applications_2026q1.csv
{"ALERT": ["debt_ratio", "credit_utilization", "late_payments_12m"], "retrain": true}
$ python -m pytest -q
.....                                                                    [100%]
5 passed in 0.32s
$ python src/local_demo.py   # 模擬 Lambda 評分
{"model_version": "v20261104150738", "pd": 0.7957, "decision": "MANUAL_REVIEW_HIGH_RISK", "top_factors":
["late_payments_12m", "credit_utilization", "debt_ratio"]}
{"model_version": "v20261104150738", "pd": 0.0131, "decision": "AUTO_APPROVE", "top_factors":
["late_payments_12m", "credit_utilization", "debt_ratio"]}
$ cat models/registry.json | tail -1 (節錄)
{"version": "v20261104150738", "champion": "logistic", "status": "staging", "sha256": "c79daa00a4ff"}
```

圖 B1　全新 clone 後執行 make all、pytest 與本機評分的實際輸出

重現步驟（Learner Lab）：1. Start Lab，將 AWS CLI 憑證貼到 ~/.aws/credentials；2. `pip install -r requirements.txt && make all`（10,100 筆 → 10,000 筆）；3. `bash aws/deploy_learner_lab.sh`：建立加密 S3、上傳三層資料與模型、Athena 建表查詢、建立 DynamoDB 與 Lambda 並呼叫一次；4. 在 Athena 主控臺執行 `SELECT COUNT(*) FROM fincloud_risk.features` 應爲 10,000；5. DynamoDB risk_score_audit 可看到評分紀錄；6. 結束後按 End Lab。

附錄 C　參考資料

Board of Governors of the Federal Reserve System. (2011). *SR 11-7: Guidance on model risk management*.

金融監督管理委員會. (2023). *金融機構作業委託他人處理內部作業制度及程序辦法*（112 年 8 月 4 日修正）.

金融監督管理委員會. (2024). *金融業運用人工智慧（AI）指引*（2024 年 6 月 20 日）.

Siddiqi, N. (2017). *Intelligent credit scoring* (2nd ed.). Wiley.

Amazon Web Services. (2025). *AWS Well-Architected Framework: Machine learning lens*.